推理系统-模型小型化

Transformer小型化

ZOMI

Talk Overview

1. **推理系统介绍**
   - 推理系统与推理引擎
   - 推理系统的工作流程
   - 推理系统生命周期管理
2. **模型小型化**
   - NAS神经网络搜索
   - CNN小型化结构
   - Transform小型化结构
3. **离线优化压缩**
   - 低比特量化
   - 二值化网络
   - 模型模型剪枝
   - 模型模型蒸馏
4. **部署和运行优化**
   - 图转换优化（算子融合/重排/替换）
   - 并发执行与内存分配
   - 动态batch与bin Packing

深度学习模型发展

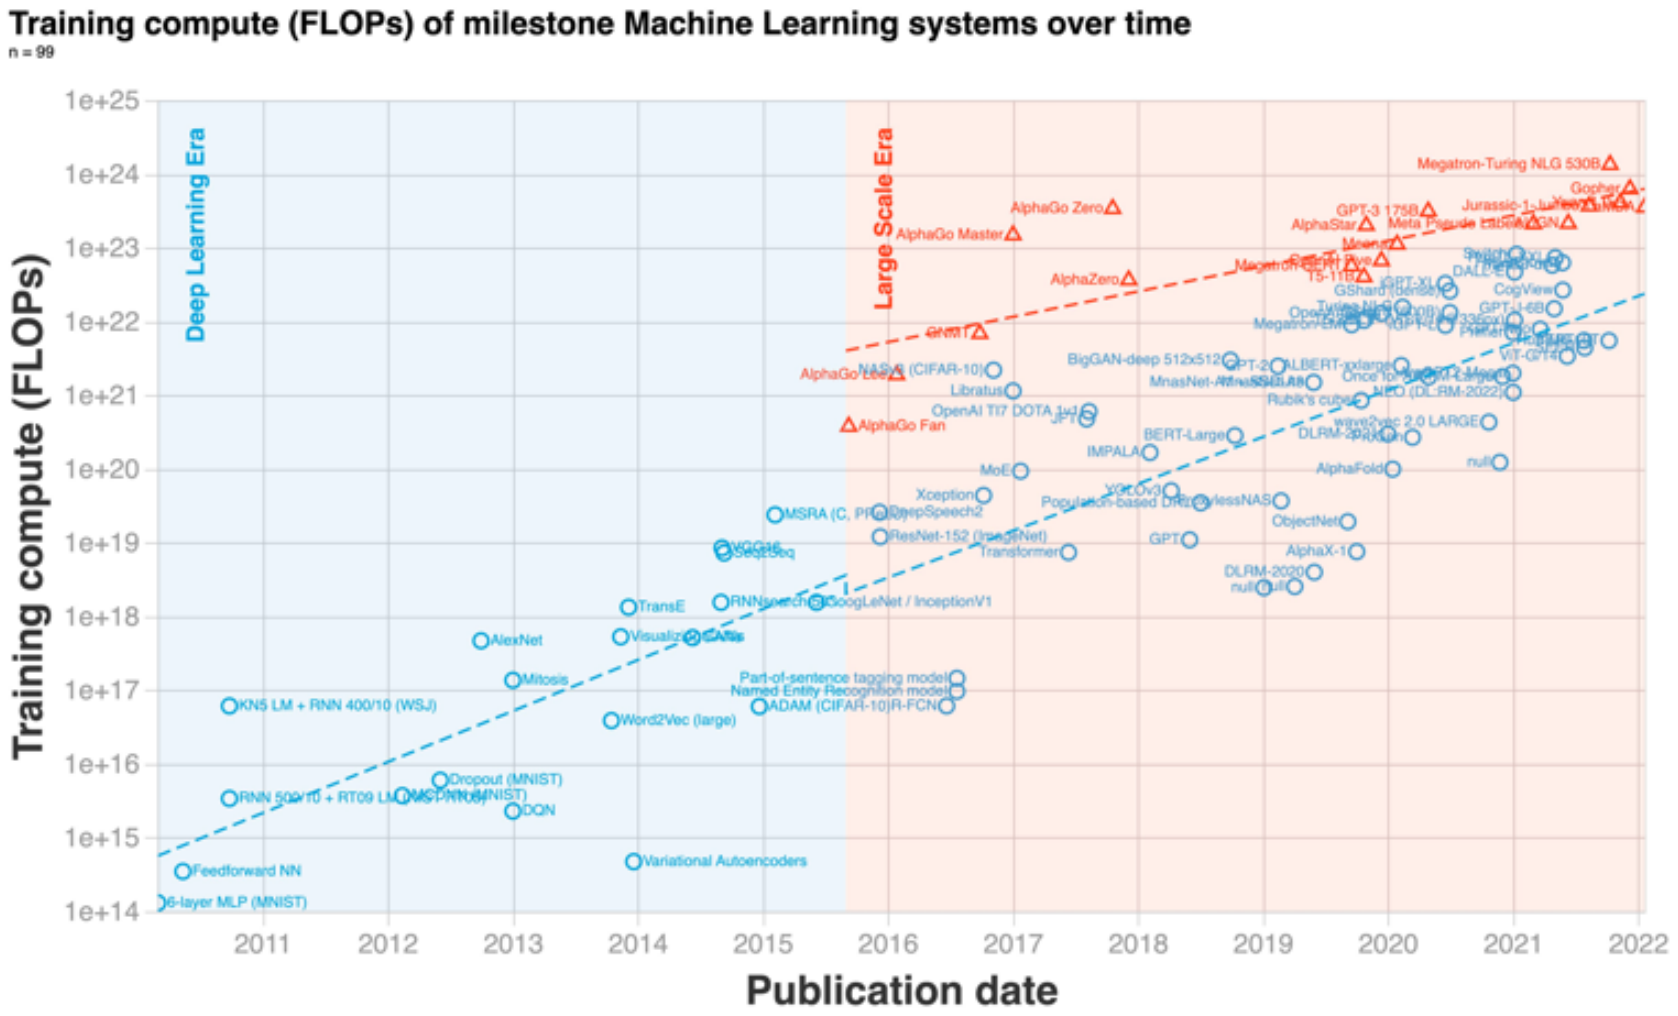

轻量级模型

1. MobileViT（2021）
2. Mobile-Former（2021）
3. EfficientFormer（2022）

轻量化网络总结

如何选择轻量化网络：

1. 不同网络架构，即使 FLOPs 相同，但其 MAC 也可能差异巨大
2. FLOPs 低不等于 latency 低，结合具硬件架构具体分析
3. 多数时候加速芯片算力的瓶颈在于访存带宽
4. 不同硬件平台部署轻量级模型需要根据具体业务选择对应指标